BÀI TẬP LỚN CO4033

PHÂN KHÚC KHÁCH HÀNG THEO HÀNH VI MUA SẮM

RFM, K-Means, Gaussian Mixture và BIRCH
trên dữ liệu giao dịch cửa hàng điện tử

Đề tài 04 | Báo cáo thực nghiệm

Ngày hoàn thiện 06/11/2026

Tóm tắt

Báo cáo xây dựng một pipeline tái lập để phân khúc khách hàng từ dữ liệu giao dịch thực tế năm 2020. Pipeline làm sạch dữ liệu, tổng hợp RFM, so sánh baseline theo ngưỡng với K-Means, Gaussian Mixture và BIRCH, sau đó cung cấp artifact cho dashboard Streamlit.

Kết quả chính
Từ 2.633.521 dòng nguồn, pipeline giữ 600.784 dòng hợp lệ và tạo RFM cho 234.359 khách. K-Means k = 3 được đề xuất làm góc nhìn vận hành mặc định vì ba nhóm đủ lớn, Silhouette đạt 0,3470 và trung vị thời gian fit là 0,774 giây. BIRCH đạt Silhouette 0,4862 nhưng cụm nhỏ nhất chỉ chiếm 0,095%, nên không đạt tiêu chí 1% đã chốt.

Kết quả chỉ đại diện cho phần giao dịch có customer_id và vượt qua quy tắc chất lượng. Mọi đề xuất CRM trong báo cáo là giả thuyết cần kiểm tra bằng thử nghiệm có nhóm đối chứng; phân khúc không chứng minh tác động nhân quả.

Mục lục

- 1 Bài toán và phạm vi
- 2 Dữ liệu và kiểm soát chất lượng
- 3 Phương pháp
- 4 Thiết kế thực nghiệm
- 5 Kết quả
- 6 Dashboard và giả thuyết CRM
- 7 Kiểm thử và khả năng tái lập
- 8 Giới hạn và kết luận
- Phụ lục A Artifact bàn giao
- Phụ lục B Phân công đóng góp
- Tài liệu tham khảo

1 Bài toán và phạm vi

1.1 Câu hỏi kinh doanh

- Khách hàng khác nhau như thế nào về thời gian mua gần nhất, số lần mua và giá trị mua?
- Nhóm khách nào có giá trị mua cao nhưng đã lâu chưa quay lại và nên được ưu tiên trong một thử nghiệm tái tương tác?
- Baseline RFM, K-Means, GMM và BIRCH khác nhau thế nào về mức phân tách, quy mô nhóm, thời gian fit và khả năng giải thích?

1.2 Người dùng và sản phẩm

Người dùng chính là nhân viên CRM hoặc quản lý marketing của cửa hàng điện tử. Sản phẩm gồm pipeline dữ liệu, pipeline phân khúc, bảng kết quả, dashboard Streamlit, báo cáo và slide. Dashboard không huấn luyện lại mô hình; nó đọc nhãn và KPI đã được pipeline tạo và kiểm tra.

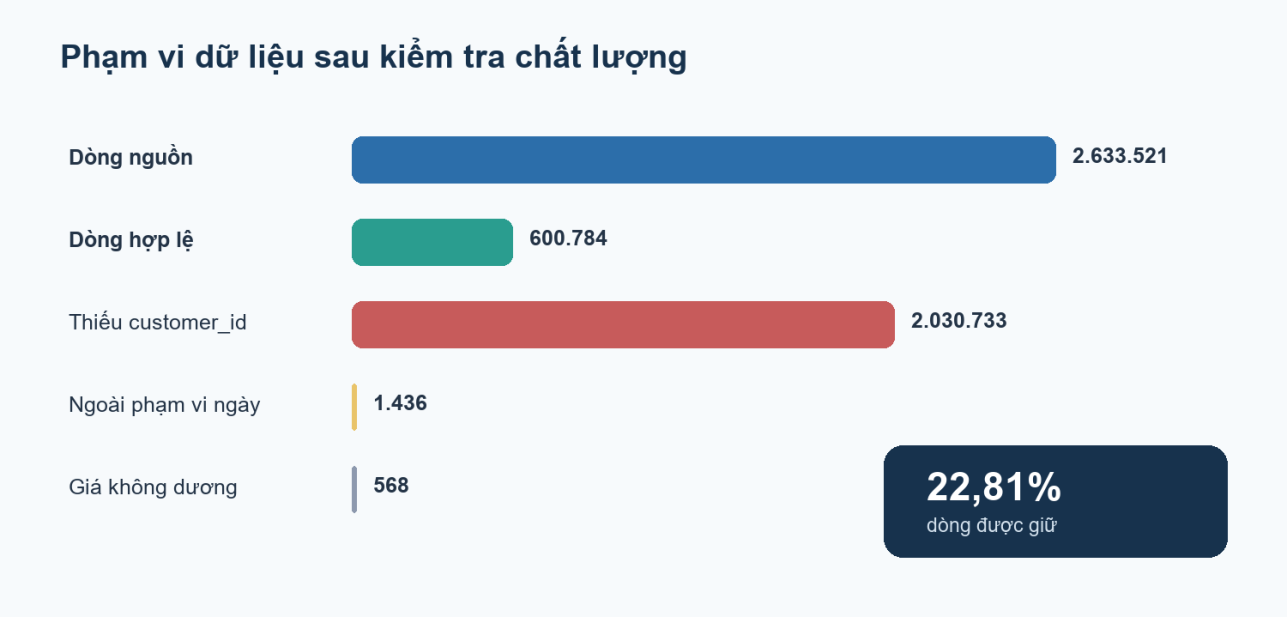
1.3 Định nghĩa KPI

KPI	Định nghĩa trong dự án	Điều không được suy diễn
Recency	Số ngày từ lần mua hợp lệ gần nhất đến 22/11/2020	Không phải xác suất rời bỏ
Frequency	Số order_id riêng biệt của khách trong kỳ	Không đếm số dòng sản phẩm
Monetary	Tổng price trên dòng hợp lệ	Không phải lợi nhuận hoặc CLV
Khách mua lặp	Khách có F >= 2 chia tổng khách RFM	Không phải retention của cohort tương lai
Silhouette	Độ tách cụm trong không gian đã chuẩn hóa	Không phải độ chính xác hoặc hiệu quả CRM

2 Dữ liệu và kiểm soát chất lượng

2.1 Nguồn và phiên bản

Dữ liệu eCommerce Purchase History from Electronics Store do REES46/Open CDP công bố. Nhóm dùng file kz.csv từ Kaggle Version 2, gồm các trường thời gian, đơn hàng, sản phẩm, ngành hàng, thương hiệu, giá và mã khách ẩn danh. File gốc không được commit vào Git.



Hình 1 Phạm vi dữ liệu sau kiểm tra chất lượng

2.2 Quy tắc làm sạch

- Giữ giao dịch năm 2020 có event_time, order_id, user_id và price hợp lệ; price phải dương.
- Căn dòng 6 trường theo cấu trúc nguồn đã quan sát; 37.961 dòng sửa cấu trúc được chấp nhận.
- Không tự điền customer_id, không thay giá thiếu bằng 0 và không xóa dòng lặp khi nguồn không có khóa dòng duy nhất.
- Tách dòng không hợp lệ kèm lý do để đo ảnh hưởng của từng quy tắc.

Chỉ số	Giá trị
Dòng nguồn	2.633.521
Dòng hợp lệ	600.784
Dòng bị tách	2.032.737
Khách hàng RFM	234.359
Đơn hàng	402.993
Khách mua lặp	74.783 (31.9096%)
Tổng M	118.372.961,62 đơn vị giá theo nguồn

Giới hạn độ bao phủ
600.784 dòng hợp lệ chiếm 22,81% số dòng nguồn. Nguyên nhân lớn nhất là thiếu customer_id. Kết quả phân khúc không đại diện cho các giao dịch không thể gắn với khách.

3 Phương pháp

3.1 RFM và baseline

Ngày chốt được cố định ở 22/11/2020, một ngày sau giao dịch hợp lệ cuối cùng. Baseline dùng percentile rank; điểm R đảo chiều còn F và M cùng chiều. Cách xếp hạng trung bình giữ các khách có F bằng nhau trong cùng ngưỡng. Năm quy tắc có thứ tự ưu tiên, loại trừ lẫn nhau và phủ 100% khách.

Nhóm baseline	Số khách	Tỷ trọng	Median R/F/M	Tỷ trọng M
Khách hàng nổi bật	30.716	13,11%	40 / 3 / 850,94	36,34%
Giá trị cao cần tái tương tác	40.775	17,40%	135 / 1 / 465,25	22,00%
Khách hàng trung thành	30.080	12,84%	97 / 2 / 386,26	21,10%
Khách hàng cần quan tâm	55.255	23,58%	148 / 1 / 57,85	3,61%
Khách hàng mới hoặc tiềm năng	77.533	33,08%	31 / 1 / 115,72	16,96%

3.2 Chuẩn bị đặc trưng

Ma trận mô hình dùng thứ tự R, F, M. Pipeline áp dụng log1p cho ba đặc trưng không âm rồi dùng StandardScaler. RFM gốc được giữ lại để tính KPI và giải thích. Tất cả phương pháp học máy dùng cùng scaler, cùng cohort và cùng thứ tự khách.

Đặc trưng	Giá trị nhỏ nhất	Giá trị lớn nhất	Trung bình sau log1p	Độ lệch dùng chuẩn hóa
recency_days	1.00	322.00	4.1350	1.0475
frequency_orders	1.00	178.00	0.9041	0.3731
monetary_value	0.02	68,035.60	5.1948	1.5809

3.3 Thuật toán

- K-Means tối thiểu hóa tổng bình phương khoảng cách đến tâm cụm. Grid thử k từ 3 đến 6, n_init = 20, seed = 42.
- Gaussian Mixture dùng covariance_type = full, n_init = 3 và gán nhãn theo xác suất hậu nghiệm lớn nhất.
- BIRCH gom dữ liệu thành subcluster trước khi tạo số cụm cuối; grid thử threshold 0,3, 0,5 và 0,7 với k từ 3 đến 6.

4 Thiết kế thực nghiệm

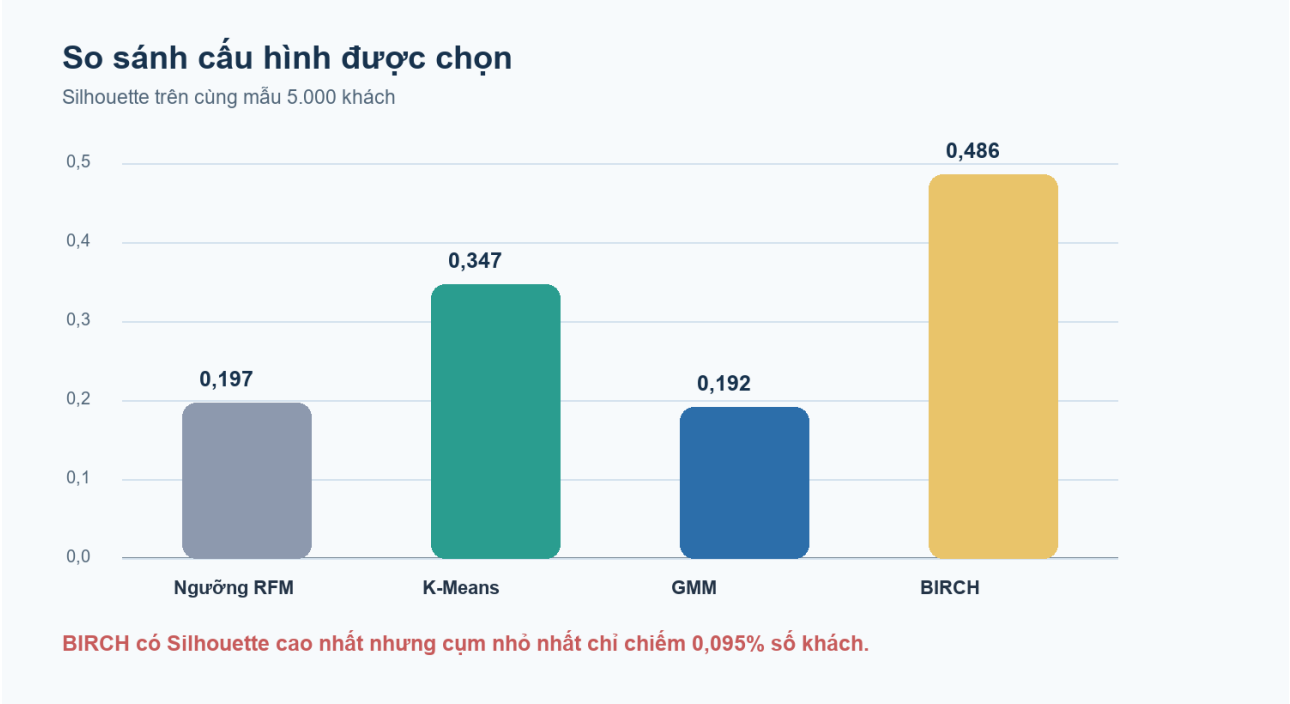
4.1 Nguyên tắc so sánh

- Huấn luyện và gán nhãn trên toàn bộ 234.359 khách.
- Tính Silhouette trên cùng mẫu cố định 5.000 khách, seed 42; hash mẫu được lưu trong run_metadata.json.
- Làm nóng một lần, đo fit_predict ba lần và báo cáo trung vị; thời gian Silhouette không nằm trong thời gian fit.
- Chỉ chọn cấu hình có cụm nhỏ nhất từ 1% trở lên. Nếu một phương pháp không có cấu hình đạt ngưỡng, dùng fallback Silhouette hợp lệ cao nhất và cảnh báo.

4.2 Môi trường

Thành phần	Giá trị
Hệ điều hành	Windows-11-10.0.26300-SP0
CPU logic	12
Python	3.12.14
NumPy	2.5.4
Pandas	2.3.3
PyArrow	26.0.1
scikit-learn	1.9.1

5 Kết quả



Hình 2 Silhouette của các cấu hình được chọn

Phương pháp	Cấu hình	Cụm	Silhouette	Fit trung vị	Cụm nhỏ nhất	Đủ điều kiện
Ngưỡng RFM	rfm_threshold_5	5	0,1969	Không áp dụng	12,835%	Có
K-Means	kmeans_k3	3	0,3470	0,774 s	21,470%	Có
GMM	gmm_k3	3	0,1919	3,534 s	14,524%	Có
BIRCH	birch_k3_t0.7	3	0,4862	2,567 s	0,095%	Không, fallback

5.1 Quyết định mô hình

K-Means k = 3 là lựa chọn mặc định cho dashboard và thảo luận CRM. Mô hình đạt Silhouette 0,3470, có nhóm nhỏ nhất 21,47% và fit nhanh hơn GMM cùng BIRCH được chọn. Baseline RFM được giữ như góc nhìn minh bạch theo quy tắc. BIRCH không được khuyến nghị làm phân khúc chính vì cấu hình fallback dồn 97,42% khách vào S1 và chỉ có 223 khách ở S3.



Hình 3 Hồ sơ ba nhóm K-Means trên toàn bộ cohort

5.2 Đọc hồ sơ K-Means

- S1 gồm 50.318 khách, chiếm 21,47% số khách nhưng 59,69% tổng M. Median R/F/M là 78 ngày, 3 đơn và 909,48.
- S2 gồm 121.895 khách, chiếm 52,01% số khách và 27,41% tổng M. Median R/F/M là 119 ngày, 1 đơn và 150,44.
- S3 gồm 62.146 khách, chiếm 26,52% số khách và 12,90% tổng M. Median R/F/M là 19 ngày, 1 đơn và 104,14.

6 Dashboard và giả thuyết CRM

6.1 Thiết kế dashboard

Dashboard có bốn tab: phạm vi dữ liệu, hồ sơ phân khúc, so sánh phương pháp và giả thuyết CRM. Bộ lọc phương pháp và phân khúc chỉ lọc artifact đã tạo; nó không làm thay đổi ngày chốt hoặc huấn luyện lại mô hình. customer_id không xuất hiện trong biểu đồ và không có chức năng tải raw data mặc định.

6.2 Danh mục thử nghiệm đề xuất

Đối tượng	Quan sát	Giả thuyết thử nghiệm	KPI chính	Rủi ro và điều kiện dừng
K-Means S1	21,47% khách; 59,69% M; 99,95% mua lặp	Quyền lợi thành viên hoặc gợi ý mua bổ sung	Đơn mới, thời gian đến đơn, M tăng thêm	Không gửi quá tần suất; dừng nếu phản hồi tiêu cực tăng

Đối tượng	Quan sát	Giả thuyết thử nghiệm	KPI chính	Rủi ro và điều kiện dừng
K-Means S2	52,01% khách; median R = 119; F = 1	Tái tương tác chi phí thấp với nhóm đối chứng	Tỷ lệ quay lại, chi phí/khách quay lại	Dừng nếu chi phí tăng mà không hơn đối chứng
K-Means S3	26,52% khách; median R = 19; F = 1	Onboarding sau mua để thúc đẩy đơn thứ hai	Đơn thứ hai trong 30/60 ngày	Kiểm soát quyền liên hệ và tỷ lệ từ chối
Baseline giá trị cao cần tái tương tác	17,40% khách; median R = 135; M = 465,25	Win-back có giới hạn ưu đãi	Lợi nhuận tăng thêm nếu có dữ liệu chi phí	Không gọi là churn khi chưa có nhãn tương lai

Nguyên tắc diễn giải
Những quan sát trên mô tả hành vi trong khoảng dữ liệu. Chúng không chứng minh khách sẽ phản hồi hoặc chiến dịch sẽ tạo doanh thu tăng thêm.

7 Kiểm thử và khả năng tái lập

7.1 Kiểm thử

Bộ kiểm thử không phụ thuộc Spark gồm 21 test và đã chạy qua sau khi merge dashboard. Test bao phủ hợp đồng schema, tie trong percentile rank, precedence baseline, cấu hình model, trường hợp metric không áp dụng, remap nhãn, ghi artifact, loader dashboard và việc không rò customer_id vào biểu đồ. Ba test PySpark vẫn cần môi trường Python 3.11 và Java 17 như README.

7.2 Lệnh chạy

Mục tiêu	Lệnh
Cài dependencies	python -m pip install -r requirements.txt
Làm sạch và RFM	python scripts/run_pipeline.py
Runner tương thích Windows	python scripts/run_portable_rfm.py
Phân khúc	python scripts/run_segmentation.py --expected-rows 234359
Kiểm thử	python -m pytest -q
Dashboard	streamlit run app/app.py

7.3 Đảm bảo tái lập

- Sắp xếp customer_id trước khi lấy mẫu và ghi file.
- Dùng seed 42 và lưu hash mẫu Silhouette.
- Lưu input SHA-256, phiên bản thư viện, cấu hình model và kết quả từng lần đo.
- Đối chiếu số khách, tổng M và khách mua lặp sau mỗi bước group-by.

7.4 Công cụ AI và kiểm chứng

Nhóm sử dụng Codex để hỗ trợ lập kế hoạch, viết mã, tạo kiểm thử và chuẩn bị tài liệu. Các số liệu được sinh từ pipeline trên dữ liệu thật và đối chiếu bằng artifact đã commit. Nhóm chịu trách nhiệm đọc mã, chạy lại lệnh, kiểm tra kết quả và trình bày đúng giới hạn.

8 Giới hạn và kết luận

8.1 Giới hạn

- Coverage theo dòng chỉ đạt 22,81% do phần lớn dòng thiếu customer_id.
- M là đơn vị giá theo nguồn; đồng tiền, lợi nhuận và chi phí chiến dịch chưa có trong dataset.
- Silhouette dùng mẫu 5.000 khách và chỉ phản ánh cấu trúc trong không gian RFM đã biến đổi.
- Khoảng dữ liệu kết thúc năm 2020; cần đánh giá drift trước khi áp dụng cho dữ liệu hiện tại.
- Không có nhãn churn hoặc kết quả chiến dịch, nên mọi hành động chỉ là giả thuyết cần thử nghiệm.

8.2 Kết luận

Dự án đã hoàn thành pipeline từ dữ liệu giao dịch đến RFM, bốn phương pháp phân khúc, benchmark, artifact và dashboard. K-Means k = 3 tạo ba nhóm đủ lớn và dễ dùng cho thảo luận CRM, trong khi baseline cung cấp quy tắc minh bạch cho các tệp chiến dịch cụ thể. BIRCH cho thấy vì sao không nên chọn mô hình chỉ dựa trên một chỉ số: Silhouette cao đi kèm phân bố cụm không phù hợp với vận hành. Bước tiếp theo hợp lý là chạy A/B test có nhóm đối chứng và cập nhật phân khúc trên dữ liệu mới.

Phụ lục A Artifact bàn giao

Artifact	Vai trò
data/processed/customer_rfm.parquet	Một dòng cho mỗi khách và RFM gốc
data/curated/customer_segments.parquet	Nhãn của bốn phương pháp và RFM gốc
reports/model_comparison.csv	Kết quả 21 cấu hình và lựa chọn
reports/segment_profiles.csv	Quy mô, median RFM, tỷ trọng M và mua lặp
reports/model_selection.json	Cấu hình được chọn và ánh xạ nhãn ổn định
reports/run_metadata.json	Seed, sample hash, môi trường và metadata feature
app/app.py	Dashboard Streamlit

Phụ lục B Phân công đóng góp

Vai trò	Phạm vi
Người 1	Khảo sát dữ liệu, quy tắc chất lượng, PySpark, Parquet và RFM
Người 2	Hợp đồng dữ liệu, baseline, K-Means, GMM, BIRCH, benchmark và profile
Người 3	Dashboard, biểu đồ, diễn giải CRM, tài liệu trình bày và demo
Cả nhóm	Đối chiếu KPI, review giới hạn, chạy lại README và tập trình bày

Tài liệu tham khảo

[1] REES46. Ecommerce behavior data. https://data.rees46.com/

[2] Kaggle. eCommerce purchase history from electronics store. https://www.kaggle.com/datasets/mkechinov/ecommerce-purchase-history-from-electronics-store

[3] Apache Spark. PySpark documentation. https://spark.apache.org/docs/latest/api/python/

[4] scikit-learn. Clustering and Gaussian mixture documentation. https://scikit-learn.org/stable/

[5] Streamlit. Documentation. https://docs.streamlit.io/